

Aufgabe1: Entwickle eine batch-basierte Datenarchitektur für eine datenintensive Applikation

1-Einleitung

Das vorliegende Data-Engineering-Projekt basiert auf dem Entwurf einer End-to-End-Pipeline, die einen auf Batch basierenden Prozess implementiert. Diese Pipeline durchläuft alle wesentlichen Schritte einer Extraktionslinie, von der anfänglichen Verarbeitung bis hin zur Verwendung robuster Technologien, einschließlich Python und Docker-Compose. Alle Datenverarbeitungsprozesse wurden mithilfe von Docker containerisiert, um den Einsatz zu vereinfachen und die Skalierbarkeit des Systems zu gewährleisten. Ich arbeite mit einem Datensatz, der mehr als 11.000 Athleten in 47 Disziplinen umfasste, die Teil von 743 Teams waren, die an den Olympischen Spielen 2021 (2020) in Tokio teilnahmen. Der Datensatz enthält Informationen wie die Namen der Athleten, die vertretenen Länder, die Sportart, das Geschlecht der Teilnehmer und die Namen der Trainer. Die Daten sind im CSV-Format organisiert, um eine effiziente Handhabung zu ermöglichen.

Ziel dieses Projekts ist es, die Effizienz und Robustheit der Datenverarbeitungspipeline im spezifischen Kontext der Olympischen Spiele 2021 zu demonstrieren und damit eine solide Grundlage für weitere Analysen und informierte Entscheidungen zu bieten.

2-Methode

Um die Verarbeitung der riesigen Datensätze zu optimieren und ihren Wert zu steigern, konzentrierten wir uns auf wichtige Elemente einer Qualitätsinfrastruktur wie die Datenerfassung, -umwandlung und -speicherung. Ursprünglich wurden die Rohdaten auf GitHub gespeichert. Mithilfe von Python-Code leiteten wir die Ingestionsphase ein, indem wir über URL eine direkte Verbindung zu GitHub herstellten. Nachdem die Daten in unser System extrahiert wurden, haben wir sie umgewandelt.

Die auf unsere Daten angewandten Transformationen sind vielfältig und umfassen Vorgänge wie die Normalisierung von Datentypen, die Korrektur von Ausreißern mithilfe statistischer Methoden wie der Mittelwertbildung sowie das Hinzufügen von Spalten zu anderen Tabellen, um Berechnungen durchzuführen, die für zukünftige Analysen erforderlich sind. Die Datenspeicherung erfolgte mithilfe von Docker-compose, das alle umgewandelten Daten in einer eigens dafür vorgesehenen Datei erhält. Unser Datenverwaltungssystem ist auf Einfachheit ausgelegt und ermöglicht eine problemlose Integration in andere Systeme, selbst bei großen Datenmengen.

Dieser Ansatz bietet die nötige Flexibilität, um unser Datensystem weiter in andere Infrastrukturen zu integrieren, und nimmt damit die Verwaltung immer größerer Datenmengen in der Zukunft vorweg.

3- Datenarchitektur




Abbildung1: Pipeline für unser Batch-Prozess.

4-Ergebnis der Analyse




Abbildung2: Prozentualer Anteil der Athleten nach Geschlecht (Frauen:42,72% | Männer:51,28%)




Abbildung3: Top 10 der Länder, die die meisten Goldmedaillen gewonnen haben (1: USA, 2: China, 3: Jetc.).




Abbildung4: Anzahl der Trainer pro Veranstaltung

5-Fazit

Unsere Datenverarbeitungsarchitektur garantiert eine qualitativ hochwertige Ausgabe, die Sicherheit und kontinuierliche Integration über Docker und Github gewährleistet. Unser System ist skalierbar, um den Anforderungen massiver Datenmengen gerecht zu werden, und vereint Einfachheit und Flexibilität, was einen nahtlosen Einsatz auf anderen Plattformen ohne das Risiko von Fehlfunktionen begünstigt.